

SISTEMA DE IDENTIFICACIÓN AUTOMÁTICA DE FAUNA

MEDIANTE BIOACÚSTICA E INTELIGENCIA ARTIFICIAL

Marco Teórico, Estado del Arte y Arquitectura del Sistema

Autor: Ian (Ingeniero en Sistemas Computacionales)

Área: Bioacústica Computacional · Visión por Computadora · Deep Learning

Mayo 2026

Grupos Taxonómicos Objetivo
Mamíferos (murciélagos, roedores, primates, carnívoros)
Anfibios (anuros: ranas y sapos)
Reptiles (cocodrilos, tortugas, lagartos con vocalización)
Insectos acústicos (grillos, cigarras, ortópteros)
Aves (referencia cruzada y validación metodológica)

Tabla de Contenidos

1. Resumen Ejecutivo

El presente proyecto propone el diseño e implementación de un sistema automatizado de identificación de fauna silvestre (mamíferos, anfibios, reptiles e insectos) mediante análisis de señales bioacústicas y técnicas de Inteligencia Artificial. El sistema integra un pipeline completo que abarca desde la adquisición de audio en campo hasta la clasificación taxonómica en tiempo real, empleando arquitecturas de deep learning sobre representaciones espectrales de las vocalizaciones.

La identificación acústica de especies representa una alternativa no invasiva, escalable y automatizable al monitoreo biológico tradicional. Su aplicación permite el seguimiento de biodiversidad a largas escalas temporales y espaciales con bajo costo operativo, superando las limitaciones de observación directa o captura física. Este sistema está diseñado con criterios de reproducibilidad científica, modularidad computacional y aplicabilidad en ecosistemas de alta biodiversidad.

La arquitectura propuesta combina extracción de características espectrales (espectrogramas Mel, MFCC, chroma), modelos de clasificación basados en Redes Neuronales Convolucionales (CNN) y arquitecturas transformer de audio, una base de datos relacional para gestión de registros biológicos, y una API REST para acceso e integración en tiempo real.

2. Introducción

La bioacústica es la disciplina científica que estudia la producción, transmisión y recepción de sonidos en organismos vivos, así como la función biológica de dichas señales (Pijanowski et al., 2011).

El monitoreo acústico pasivo (PAM) emerge como metodología estándar en ecología de campo para la detección y seguimiento de especies mediante grabaciones ambientales continuas. La automatización del análisis de estas grabaciones mediante Inteligencia Artificial representa un cambio de paradigma en la biología de conservación: permite procesar volúmenes de datos imposibles de analizar manualmente y detectar patrones temporales, espaciales y taxonómicos a escalas previamente inaccesibles.

Justificación de la investigación:

- La biodiversidad sonora contiene información taxonómica precisa: cada especie produce vocalizaciones con características espectrales y temporales distintivas.
- Los métodos tradicionales de identificación (observación directa, trampas, capturas) son invasivos, costosos y de baja cobertura espacio-temporal.
- Los avances en deep learning y el crecimiento de bases de datos bioacústicas abiertas (Xeno-canto, iNaturalist, GBIF, Macaulay Library) hacen viable el entrenamiento de modelos robustos.
- El monitoreo continuo 24/7 mediante dispositivos de bajo costo (AudioMoth, Raspberry Pi + micrófono) permite adquisición masiva de datos en zonas remotas.

3. Marco Teórico

3.1 Fundamentos de Bioacústica

La bioacústica integra principios de acústica física, fisiología animal y ecología del comportamiento. Las señales sonoras producidas por animales pueden clasificarse según su función biológica en: señales de comunicación intraespecífica (llamadas de apareamiento, territorialidad, alarma), señales de ecolocalización (quirópteros, cetáceos), y sonidos de producción incidental (movimiento, alimentación).

3.1.1 Parámetros acústicos fundamentales

Parámetro	Símbolo	Definición	Relevancia taxonómica
Frecuencia fundamental	F_0 (Hz)	Frecuencia más baja del espectro armónico	Alta: varía por especie y grupo taxonómico

Frecuencia dominante	Fdom (Hz)	Frecuencia de mayor energía espectral	Alta: discrimina especies con vocalizaciones similares
Duración de llamada	D (ms)	Longitud temporal del evento acústico	Media: diagnóstica en combinación con otros parámetros
Tasa de repetición	PRR (calls/s)	Número de llamadas por unidad de tiempo	Alta: refleja estado fisiológico y especie
Ancho de banda	BW (kHz)	Rango de frecuencias del evento (F_max - F_min)	Alta: distingue llamadas de banda estrecha/ancha
Modulación de frecuencia	FM (Hz/ms)	Tasa de cambio de frecuencia en el tiempo	Alta: diferencia murciélagos FM vs CF
Entropía espectral	H	Medida de aleatoriedad espectral	Media: discrimina tono puro vs ruido de banda ancha

3.1.2 Ecoacústica y soundscape ecology

La ecoacústica estudia la contribución de los sonidos biológicos (biofonía), geofísicos (geofonía) y antropogénicos (antrofonía) al paisaje sonoro total (Pijanowski et al., 2011). Los índices acústicos derivados de grabaciones ambientales permiten estimar riqueza de especies y diversidad biológica sin identificación individual:

ADI (Acoustic Diversity Index): Mide la distribución de energía entre bandas de frecuencia. Correlaciona positivamente con riqueza de especies en sistemas bien caracterizados.

ACI (Acoustic Complexity Index): Cuantifica la variación en intensidad dentro de cada banda de frecuencia. Discrimina biofonía de antrofonía.

BI (Bioacoustic Index): Suma de diferencias de amplitud entre la banda biológica activa (2-8 kHz) y el ruido de fondo.

3.2 Características acústicas por grupo taxonómico

3.2.1 Mamíferos

Los mamíferos presentan la mayor diversidad de mecanismos de producción sonora. Los quirópteros (murciélagos) son el grupo más estudiado en bioacústica dada su dependencia evolutiva de la ecolocalización. Sus llamadas ultrasónicas (20-200 kHz) son de alta especificidad taxonómica y pueden clasificarse en cuatro tipos según su estructura temporal y espectral:

Tipo de llamada	Rango frecuencial	Estructura	Géneros representativos
FM (Frequency Modulated)	25-100 kHz	Barrido descendente de banda ancha	Myotis, Perimyotis, Eptesicus
CF (Constant Frequency)	20-120 kHz	Tono puro de frecuencia estable	Rhinolophus, Pteronotus
FM-CF	20-80 kHz	Combinación de barrido +	Hipposideros, Rhinolophus

		tono	
QCF (Quasi Constant Frequency)	20-60 kHz	Barrido muy lento, casi plano	Tadarida, Molossus

Los primates, roedores y carnívoros producen vocalizaciones en el rango audible (0.1-20 kHz) con estructuras armónicas complejas, llamadas de alarma, y comunicaciones de alta frecuencia (ultrasónicas en roedores, especialmente *Mus musculus* con llamadas USV a 50 kHz). La identificación automática de mamíferos no voladores por bioacústica es metodológicamente más compleja debido a la mayor variabilidad intraespecífica y la dependencia contextual de las vocalizaciones.

3.2.2 Anfibios (Anuros)

Los anuros (ranas y sapos) son el grupo más accesible para monitoreo bioacústico debido a la alta especificidad de sus cantos de anuncio (advertisement calls). La producción sonora ocurre principalmente en machos durante la época reproductiva y es mediada por sacos vocales resonadores. Las vocalizaciones presentan estructura temporal periódica (trinos, pulsos) y características espectrales altamente diagnósticas a nivel de especie:

- Frecuencia dominante (F_{dom}): rasgo altamente conservado taxonómicamente, determinado por el tamaño corporal (correlación negativa).
- Tasa de repetición de pulsos (pulse rate): varía entre 5-200 pulsos/segundo según especie y temperatura ambiental (relación lineal).
- Duración del canto: desde 50 ms (*Eleutherodactylus*) hasta llamadas continuas de varios segundos (*Bufo*).
- Estructura armónica: presencia/ausencia de armónicos y sus relaciones de amplitud son diagnósticas.

3.2.3 Insectos acústicos

Los ortópteros (grillos, saltamontes, esperanzas) producen sonido por estridulación: fricción entre estructuras quitinosas (pectro y lima en las alas). Las cigarras (Hemiptera: Cicadidae) emplean membranas timpanales (timbales) para producir sonidos de alta intensidad (>80 dB SPL). Características diagnósticas clave:

Grupo	Mecanismo	Rango (kHz)	Rasgo diagnóstico
Grillos (<i>Gryllidae</i>)	Estridulación alar	3-10	Tasa de pulsos, estructura del chirp
Saltamontes (<i>Acrididae</i>)	Estridulación fémur-ala	4-50	Patrón temporal del estridulema
Cigarras (<i>Cicadidae</i>)	Timbal resonante	1-20	Duración de frase, modulación AM
Katyids (<i>Tettigoniidae</i>)	Estridulación alar	5-100+	Alta frecuencia, ultra-sónico en muchas spp.

3.2.4 Reptiles

Los reptiles son el grupo con menor repertorio acústico. La mayoría de los escamosos (lagartos y serpientes) son afonos; sin embargo, algunos grupos presentan vocalizaciones audibles:

- Cocodrilos (Crocodylia): producen bellows (mugidos graves) de alta intensidad durante el cortejo y defensa territorial. Frecuencia dominante 50-400 Hz.
- Tortugas marinas y de agua dulce: reportes recientes de vocalizaciones subacuáticas en frecuencias muy bajas (100-1000 Hz).
- Geckos (Gekkota): producen clics, ladridos y chirps para comunicación territorial. Rango: 1-16 kHz.
- Tuatara (*Sphenodon punctatus*): produce gruñidos audibles únicamente en animales adultos durante defensa territorial.

3.3 Procesamiento Digital de Señales de Audio

3.3.1 Representaciones tiempo-frecuencia

La transformada de Fourier de tiempo corto (STFT) es la operación fundamental para convertir una señal temporal en una representación tiempo-frecuencia. Dado un segmento de audio $x[n]$ con función de ventana $w[n]$:

$$\text{STFT}\{x[n]\}(m, k) = \sum_n x[n] \cdot w[n - mH] \cdot e^{(-j2\pi kn/N)}$$

donde m es el índice de frame, k es el bin de frecuencia, H es el hop length y N es el tamaño de la FFT. El espectrograma (magnitud al cuadrado de la STFT) es la representación estándar para análisis visual e input a modelos de clasificación.

3.3.2 Escala Mel y espectrogramas Mel

La escala Mel aproxima la percepción logarítmica de frecuencia del sistema auditivo de los vertebrados. La conversión de frecuencia Hz a escala Mel es:

$$\text{mel}(f) = 2595 \cdot \log_{10}(1 + f/700)$$

El espectrograma Mel se obtiene aplicando un banco de filtros triangulares distribuidos en escala Mel sobre el espectrograma STFT. Para fauna en rangos audibles (0.1-20 kHz), se recomienda usar 64-128 bandas Mel. Para ultrasonido (quirópteros), se requieren representaciones lineales de frecuencia o escala logarítmica invertida.

3.3.3 Coeficientes MFCC

Los Mel Frequency Cepstral Coefficients (MFCCs) son la representación estándar en reconocimiento de voz y se aplican extensamente en clasificación bioacústica. Se obtienen aplicando la Transformada Discreta del Coseno (DCT) al logaritmo del espectro Mel:

$$MFCC[n] = \sum_{m=1}^M \log(S[m]) \cdot \cos[n(m - 0.5)\pi/M]$$

En la práctica se emplean los primeros 13-40 coeficientes MFCC junto con sus primeras y segundas derivadas temporales (delta y delta-delta), proporcionando un vector de características de 39-120 dimensiones por frame. Los MFCC capturan la forma espectral del sonido pero descartan información de fase y energía absoluta.

3.4 Detección de Eventos Sonoros

Antes de la clasificación, es necesario segmentar la grabación continua en eventos de interés (ROI: Regions of Interest). Los métodos principales son:

Método	Principio	Ventajas	Limitaciones
Energy Thresholding	Umbral de energía RMS por frame	Simple, rápido, sin entrenamiento	Sensible a ruido de fondo variable
Spectral Subtraction	Estimación y substracción del ruido de fondo espectral	Robusto a ruido estacionario	Artefactos musicales con ruido no estacionario
CFAR (Constant False Alarm Rate)	Umbral adaptativo local en el espectrograma	Estándar en detección de quirópteros	Requiere calibración por entorno
BirdNET-style CNN Detector	Red neuronal entrenada para discriminar bio/no-bio	Alta precisión, robusto	Requiere dataset de entrenamiento
OpenSoundscape (RIBBIT)	Template matching para llamadas periódicas (anuros)	Muy específico para llamadas rítmicas	Solo funciona con vocalizaciones periódicas

3.5 Fundamentos de Machine Learning para Clasificación Acústica

3.5.1 Redes Neuronales Convolucionales (CNN)

Las CNN son la arquitectura dominante para clasificación de espectrogramas bioacústicos. Tratan el espectrograma como una imagen bidimensional y aprenden filtros espaciales jerárquicos que detectan patrones de frecuencia-tiempo. La operación de convolución 2D es:

$$(I * K)[i,j] = \sum_m \sum_n I[i+m, j+n] \cdot K[m,n]$$

Las arquitecturas de referencia para clasificación bioacústica incluyen ResNet-18/50, EfficientNet-B0/B4, MobileNetV3 (para edge deployment) y modelos pre-entrenados en AudioSet vía transfer learning. El pre-entrenamiento en ImageNet y AudioSet ha demostrado superar al entrenamiento desde cero en datasets bioacústicos de tamaño moderado (<10,000 muestras por clase).

3.5.2 Transformers de Audio y modelos fundacionales

Los modelos de tipo Audio Spectrogram Transformer (AST) aplican el mecanismo de self-attention de los Vision Transformers (ViT) sobre patches del espectrograma. Modelos fundacionales de audio como BirdNET (Cornell Lab), PANNs (Pretrained Audio Neural Networks) y Wav2Vec2 son candidatos a fine-tuning para identificación de fauna. El modelo PANNs-CNN14 pre-entrenado en AudioSet (~2M clips, 527 clases) ofrece embeddings de audio de 2048 dimensiones altamente transferibles.

3.5.3 Métricas de evaluación

Métrica	Fórmula	Uso en clasificación multiclase
Accuracy	$TP+TN / (TP+TN+FP+FN)$	Útil solo con clases balanceadas
Precision macro	$\text{mean}(TP_c / (TP_c + FP_c))$	Detecta falsos positivos por clase
Recall macro	$\text{mean}(TP_c / (TP_c + FN_c))$	Detecta falsos negativos por clase
F1-score macro	$2 \cdot (P \cdot R) / (P + R)$	Balance P/R; estándar en literatura bioacústica
ROC-AUC (macro)	Area bajo curva ROC promediada	Independiente del umbral de decisión
CMC@K	Cumulative Match Characteristic	Para retrieval: ¿está la especie en top-K?

4. Estado del Arte

4.1 Sistemas existentes de identificación bioacústica

Sistema	Grupos objetivo	Arquitectura ML	Dataset entrenamiento	Disponibilidad
BirdNET v2.4 (Cornell)	Aves (6,000+ sp.)	EfficientNet + custom CNN	Xeno-canto + Macaulay	Open source / API
BatDetective / BatClassify	Quirópteros (Europa)	CNN + RNN sobre espectrogramas	BatCall UK, ChiroVox	Open source
ARBIMON	Aves + anfibios (Neotropical)	Template matching + RF	Puerto Rico Bioacoustic DB	SaaS (Rainforest Connection)
Frogwatch + RIBBIT	Anuros	Pattern matching + CNN	FrogID (Australia)	Open source (OpenSounds cape)
iNaturalist Sound ID	Multiespecie	CNN (EfficientNet)	iNaturalist observations	API pública
PANNs (Qiuqiang Kong)	527 categorías sonido	CNN14, MobileNet, ResNet38	AudioSet (Google)	Pesos pre-entrenados OSS
Animal Sound ID (MPEG-7)	Multiespecie	SVM + MFCC	Varios (heterogéneo)	Académico

4.2 Bases de datos bioacústicas abiertas

La disponibilidad de datos etiquetados es el factor limitante principal en sistemas de identificación bioacústica. Las siguientes bases de datos son de acceso libre y uso científico establecido:

Base de datos	Cobertura taxonómica	Nº grabaciones	Formato	URL
Xeno-canto	Aves (700K+ grabs.)	>700,000	MP3 (georef.)	xeno-canto.org
iNaturalist Sounds	Multitaxon	>500,000	MP3/WAV	inaturalist.org
Macaulay Library (Cornell)	Aves + mamíferos	>300,000 (audio)	MP3/WAV	macaulaylibrary.org
GBIF (sounds)	Multitaxon	Variable	JSON + audio URL	gbif.org
FrogID (ANTWRAP)	Anuros (Australia)	>300,000	MP3	frogid.net.au
Bat Eco-Interaction DB	Quirópteros	~50,000	WAV (ultrasonido)	batbase.org
AudioSet (Google)	527 clases sonido	~2,000,000	YouTube (10s clips)	research.google/audioset
ESC-50	50 clases ambiente	2,000	WAV 5s	github.com/karolpiczak

DCASE Challenge sets	Escenas + eventos	Variable por año	WAV	dcase.community
----------------------	-------------------	------------------	-----	-----------------

4.3 Publicaciones científicas de referencia

Las siguientes publicaciones constituyen la literatura fundacional y de frontera del campo:

Revisiones y metodología general:

- Stowell, D. (2022). Computational bioacoustics with deep learning: a review and roadmap. *PeerJ*, 10, e13152. [Revisión más completa del campo hasta 2022]
- Jäger, M. et al. (2022). Animal sound classification using transfer learning. *Ecological Informatics*, 71, 101765.
- Shiu, Y. et al. (2020). Deep neural networks for automated detection of marine mammal species. *Scientific Reports*, 10, 607.

Quirópteros:

- Mac Aodha, O. et al. (2018). Bat detective — deep learning tools for bat acoustic signal detection. *PLOS Computational Biology*, 14(3), e1005995.
- Pérez-Granados, C. (2023). Bats acoustic monitoring: a review of the current state and perspectives. *Methods in Ecology and Evolution*.

Anfibios:

- Colonna, J.F. et al. (2016). Automatic recognition of anuran species based on syllable identification. *Expert Systems with Applications*, 64, 555-567.
- Xie, J. et al. (2019). Frog Call Classification: A Survey. *Artificial Intelligence Review*, 49, 375-412.

Insectos:

- Potamitis, I. et al. (2015). Unsupervised dictionaries of insect sounds. *Expert Systems with Applications*, 42(16), 6485-6494.
- Noda, J.J. et al. (2016). Classifying insect sounds using deep neural networks. *Applied Acoustics*, 105, 1-11.

5. Metodología del Sistema

5.1 Diseño general del pipeline

El sistema propuesto implementa un pipeline de procesamiento en 6 etapas secuenciales, diseñado con principios de modularidad, reproducibilidad y escalabilidad horizontal:

Etapa	Módulo	Tecnología	Output
1. Adquisición	audio_capture	AudioMoth / PyAudio / librosa (lectura)	WAV 16-bit, 192kHz (ultrasonido) o 44.1kHz (audible)
2. Preprocesamiento	audio_processing	librosa, scipy, numpy	WAV normalizado, segmentado, ruido reducido
3. Detección de ROI	vad_detector	CFAR / Energy threshold / CNN	Timestamps de eventos + segmentos de audio
4. Extracción de features	feature_extraction	librosa, openSMILE, librosa.feature	Arrays NumPy: Mel, MFCC, chroma, spectral features
5. Clasificación	classifier	PyTorch / TensorFlow + transfer learning	Probabilidades por especie + top-K predicciones
6. Almacenamiento y API	database + api	PostgreSQL + FastAPI	JSON con detecciones, timestamps, coordenadas GPS

5.2 Hipótesis de investigación

H₁: Un modelo de deep learning entrenado con transfer learning sobre espectrogramas Mel de vocalizaciones de fauna puede clasificar correctamente ≥ 4 grupos taxonómicos (mamíferos, anfibios, reptiles, insectos) con F1-score macro ≥ 0.80 en condiciones de campo controladas.

H₂: La combinación de espectrogramas Mel + MFCC como representación de entrada supera en accuracy al uso de MFCC aislados para clasificación de vocalizaciones de múltiples grupos taxonómicos.

5.3 Objetivos del proyecto

Objetivo general:

Desarrollar un sistema computacional de identificación automática de fauna silvestre mediante análisis de señales bioacústicas utilizando técnicas de inteligencia artificial, que sea preciso, escalable y aplicable en condiciones de monitoreo pasivo en campo.

Objetivos específicos:

1. OE1: Construir un dataset multitaxonómico de vocalizaciones de fauna (mamíferos, anfibios, reptiles, insectos) con mínimo 500 muestras por clase mayoritaria.
2. OE2: Implementar un pipeline de preprocesamiento de audio que incluya eliminación de ruido, normalización, segmentación y extracción de representaciones espectrales.
3. OE3: Entrenar y comparar al menos tres arquitecturas de clasificación (CNN baseline, EfficientNet con transfer learning, AST/PANNs) sobre el dataset construido.
4. OE4: Diseñar e implementar un esquema de base de datos relacional para almacenamiento de registros biológicos, detecciones y metadatos de campo.
5. OE5: Desarrollar una API REST que exponga los modelos de clasificación para inferencia en tiempo real.
6. OE6: Validar el sistema en grabaciones de campo con evaluación por espécimen conocido ($F1 \geq 0.80$ en conjunto de prueba).

5.4 Estrategia de adquisición de datos

Fuente	Método de acceso	Grupos cubiertos	Volumen estimado
Xeno-canto API v2	REST API (GET /recordings)	Aves + validación cruzada	~50,000 grabaciones filtradas por calidad A/B
iNaturalist Sounds API	REST API + taxa filter	Multitaxon (anfibios, insectos, mamíferos)	~20,000 grabaciones
FrogID / GBIF Sounds	Bulk download + GBIF API	Anuros principalmente	~10,000 grabaciones
ChiroVox / Bat recordings	Descarga directa	Quirópteros (ultrasonido)	~5,000 grabaciones
Grabación de campo propia	AudioMoth / Zoom H5 + SMA microphone	Todos los grupos locales	Sesiones continuas 48h en múltiples sitios

6. Bibliografía

Las siguientes referencias están ordenadas por relevancia metodológica para el proyecto. El formato de citación sigue el estilo APA 7ª edición.

Bioacústica computacional — Revisiones:

7. Stowell, D. (2022). Computational bioacoustics with deep learning: a review and roadmap. *PeerJ*, 10, e13152. <https://doi.org/10.7717/peerj.13152>
8. Pijanowski, B. C., Farina, A., Gage, S. H., Dumyahn, S. L., & Krause, B. L. (2011). What is soundscape ecology? An introduction and overview of an emerging new science. *Landscape Ecology*, 26(9), 1213-1232.
9. Jäger, M., Milling, M., & Schuller, B. (2022). Animal sound classification using transfer learning from AudioSet. *Ecological Informatics*, 71, 101765.

Deep Learning para clasificación de audio:

10. Kong, Q., Cao, Y., Iqbal, T., Wang, Y., Wang, W., & Plumbley, M. D. (2020). PANNs: Large-Scale Pretrained Audio Neural Networks for Audio Pattern Recognition. *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, 28, 2880-2894.
11. Gong, Y., Liu, A. H., Yang, J., & Glass, J. (2021). SSAST: Self-Supervised Audio Spectrogram Transformer. *arXiv:2110.09784*.
12. Salamon, J., & Bello, J. P. (2017). Deep Convolutional Neural Networks and Data Augmentation for Environmental Sound Classification. *IEEE Signal Processing Letters*, 24(3), 279-283.
13. He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep Residual Learning for Image Recognition. *CVPR 2016*.
14. Tan, M., & Le, Q. (2019). EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks. *ICML 2019*.

Identificación de quirópteros:

15. Mac Aodha, O., Gibb, R., Barlow, K. E., Browning, E., Firman, M., Freeman, R., & Jones, G. (2018). Bat Detective — Deep learning tools for bat acoustic signal detection. *PLOS Computational Biology*, 14(3), e1005995.
16. Fenton, M. B., & Simmons, N. B. (2014). *Bats: A World of Science and Mystery*. University of Chicago Press.

Identificación de anfibios:

17. Xie, J., Towsey, M., Zhang, J., & Roe, P. (2019). Frog Call Classification: A Survey. *Artificial Intelligence Review*, 49(3), 375-412.
18. Colonna, J. F., Gama, J., & Nakamura, E. F. (2016). How to correctly evaluate an automatic bioacoustics classification method. In *Conference on Artificial Intelligence in Medicine in Europe* (pp. 123-132).
19. Towsey, M., Wimmer, J., Williamson, I., & Roe, P. (2014). The use of acoustic indices to determine avian species richness in audio-recordings of the environment. *Ecological Informatics*, 21, 110-119.

Herramientas de software utilizadas:

20. McFee, B. et al. (2015). librosa: Audio and Music Signal Analysis in Python. *Proceedings of the 14th Python in Science Conference (SciPy 2015)*.

21. Eusebio, P. et al. (2022). OpenSoundscape: An open-source bioacoustics Python package. *Methods in Ecology and Evolution*.
22. Lasseck, M. (2018). Audio-based Bird Species Identification with Deep Convolutional Neural Networks. *Working Notes of CLEF 2018*.
23. Kahl, S., Wood, C. M., Eibl, M., & Klinck, H. (2021). BirdNET: A deep learning solution for avian diversity monitoring. *Ecological Informatics*, 61, 101236.